

Xây dựng hệ thống tìm kiếm và tư vấn sản phẩm tiếng Việt

Hybrid Retrieval và Reranking cho truy xuất sản phẩm; hướng tới mở rộng RAG

Nhóm 14

Sinh viên thực hiện:

Nguyễn Văn Quý – B22DCKH100

Đào Thịnh Phú – B22DCKH086

Đào Văn Công – B22DCKH010

Khoa CNTT1 – PTIT

05/2026

Nội dung trình bày

- 1 Bài toán và mục tiêu
- 2 Dữ liệu và tiền xử lý
- 3 Kiến trúc hệ thống
- 4 Thực nghiệm và đánh giá

- 1 Bài toán và mục tiêu
- 2 Dữ liệu và tiền xử lý
- 3 Kiến trúc hệ thống
- 4 Thực nghiệm và đánh giá

Bài toán nhóm lựa chọn

Bối cảnh

Người dùng thường tìm sản phẩm bằng **ngôn ngữ tự nhiên**, không nhất thiết gõ đúng tên model hoặc đúng từ khóa trong dữ liệu.

Ví dụ truy vấn thực tế

- “tai nghe chống ồn dưới 2 triệu”
- “dây cáp tai nghe PWAudio giá dưới 5 triệu”
- “FiiO JD7” hoặc “ThieAudio Oracle MKIII”

Thách thức

Truy vấn có thể chứa **thương hiệu, giá, tên model, từ lóng, lỗi chính tả nhẹ** và thuật ngữ kỹ thuật tiếng Anh.

Mục tiêu và phạm vi hiện tại

Mục tiêu chính

Xây dựng hệ thống truy xuất sản phẩm tai nghe tiếng Việt, trả về **Top-K sản phẩm phù hợp** dựa trên ngữ nghĩa và các ràng buộc như thương hiệu, giá, thuộc tính.

Phạm vi phiên bản hiện tại

- Tập trung vào **retrieval và reranking**.
- Chưa khẳng định là một chatbot RAG hoàn chỉnh.
- Kết quả đầu ra chính là danh sách sản phẩm phù hợp kèm metadata.

Đóng góp chính

- ① Pipeline xử lý dữ liệu sản phẩm tiếng Việt từ crawl đến build index.
- ② Hybrid Retrieval: kết hợp **FAISS dense search** và **BM25 sparse search**.
- ③ Cross-Encoder Reranking kết hợp xử lý metadata như brand và giá.

- 1 Bài toán và mục tiêu
- 2 Dữ liệu và tiền xử lý
- 3 Kiến trúc hệ thống
- 4 Thực nghiệm và đánh giá

Dữ liệu thu thập

Nguồn dữ liệu

- Website: `tainghe.com.vn`
- Dữ liệu sản phẩm tai nghe, dây cáp, phụ kiện âm thanh
- Ngôn ngữ: tiếng Việt + thuật ngữ kỹ thuật tiếng Anh

Trường dữ liệu chính

- `url`
- `product_name`
- `brand`
- `price`
- `review_content`

Ghi chú dữ liệu

Sau bước lọc bản ghi thiếu tên hoặc review, tập dùng để build index gồm hơn **500 sản phẩm hợp lệ**. Đây là tập dữ liệu bước đầu cho bài toán môn học.

Tiền xử lý và Metadata Injection

Các bước tiền xử lý

- Chuẩn hóa giá bằng `clean_price()`.
- Chuẩn hóa text: xóa ký tự nhiễu, lower-case, chuẩn hóa khoảng trắng.
- Tách từ tiếng Việt bằng **PyVi / ViTokenizer**.
- Nhận diện thương hiệu bằng `extract_brand()` khi metadata chưa đầy đủ.

Metadata Injection

Mỗi sản phẩm được đóng gói thành văn bản có cấu trúc:

Sản phẩm: tên. Thương hiệu: brand. Giá: price. review

Lợi ích

Cả Dense Search và BM25 đều nhìn thấy thông tin **tên, thương hiệu, giá, nội dung** ≡ ▶ ≡ ↺ 🔍 ↻

- 1 Bài toán và mục tiêu
- 2 Dữ liệu và tiền xử lý
- 3 Kiến trúc hệ thống**
- 4 Thực nghiệm và đánh giá

Pipeline hệ thống

Luồng tổng thể

Crawl → Tiền xử lý → Build Index → Hybrid Retrieval → Rerank → Top-K

Offline

- Crawl dữ liệu sản phẩm
- Làm sạch và tokenize tiếng Việt
- Build FAISS index và BM25 corpus

Online

- Nhận query người dùng
- Retrieve ứng viên bằng Dense + BM25
- Rerank và xử lý ràng buộc metadata

Embedding và Vector Store

Embedding Model

- Model: `bkai-foundation-models/vietnamese-bi-encoder`
- Biểu diễn query và document thành vector **768 chiều**
- Dùng làm baseline embedding cho semantic search tiếng Việt

Vector Store

- Sử dụng **FAISS** để lưu và truy xuất vector
- Truy vấn lấy các document gần nhất trong không gian vector
- Đóng vai trò tầng **Dense Search**

Query vector gần document vector hơn $\Rightarrow$ sản phẩm có khả năng liên quan hơn.

Hybrid Retrieval: Dense + BM25

Dense Search

- Dựa trên embedding semantic
- Mạnh với truy vấn mơ hồ, đồng nghĩa, ngữ nghĩa mở rộng
- Ví dụ: “đồng nguyên chất” $\approx$ “OCC Litz”

BM25 Search

- Dựa trên exact keyword match
- Mạnh với tên model, mã sản phẩm, thương hiệu
- Ví dụ: “Oracle MKIII”, “FiiO JD7”

Ý tưởng chính

Dense và BM25 bổ sung cho nhau: một bên bắt **ngữ nghĩa**, một bên bắt **từ khóa chính xác**.

Fusion, Deduplication và Reranking

Fusion và Deduplication

- Lấy ứng viên từ Dense Search và BM25.
- Hợp nhất hai danh sách kết quả.
- Deduplicate theo **URL** để tránh trùng sản phẩm/chunk.

Cross-Encoder Reranking

- Model: BAAI/bge-reranker-v2-m3
- Chấm điểm từng cặp (query, document) bằng cross-attention
- Dừng ở bước xếp hạng cuối để chọn Top-K phù hợp hơn

Candidate pool → Cross-Encoder → Top-5 sản phẩm cuối cùng

Metadata-aware Scoring

Brand Bonus

Nếu query nhắc đến thương hiệu và sản phẩm có brand tương ứng:

$$s_{final}(q, d) = CE(q, d) + \Delta_{brand}, \text{ với } \Delta_{brand} = +0.5$$

Price Constraint

Nếu query có điều kiện giá như “dưới 5 triệu”, hệ thống parse mức giá trần và xử lý các ứng viên vượt ngân sách trong bước rerank/filter.

Tác dụng

Giúp hệ thống xử lý tốt hơn các truy vấn có ràng buộc rõ như **brand + giá + loại sản phẩm**.

Vị trí hiện tại trong hướng RAG

Mapping R – A – G

- **R – Retrieval:** Hybrid Search + Reranking để lấy Top-K sản phẩm liên quan.
- **A – Augmentation:** Đóng gói Top-K thành context gồm tên, giá, brand, review, URL.
- **G – Generation:** Phiên bản hiện tại mới ở mức tạo phản hồi có cấu trúc / định dạng kết quả; generation tự nhiên hoàn chỉnh là hướng phát triển tiếp theo.

Cách gọi chính xác

Hệ thống hiện tại là **retrieval-augmented product search**; đây là nền tảng để mở rộng thành RAG hoàn chỉnh.

- 1 Bài toán và mục tiêu
- 2 Dữ liệu và tiền xử lý
- 3 Kiến trúc hệ thống
- 4 Thực nghiệm và đánh giá

Thiết lập đánh giá

Bộ truy vấn test

- 12 câu hỏi kiểm thử.
- Bao phủ các nhóm: exact match, brand + giá, sai chính tả nhẹ, từ lóng, semantic query, query siêu ngắn.
- Mỗi query được đánh giá tại $K = 5$.

Metrics sử dụng

- **Precision@5**: Top-5 có bao nhiêu kết quả đúng.
- **HitRate@5**: Top-5 có ít nhất một kết quả đúng hay không.
- **MRR**: Kết quả đúng đầu tiên nằm cao hay thấp.
- **nDCG@5**: Chất lượng xếp hạng của toàn bộ Top-5.

Hạn chế và hướng phát triển

Hạn chế hiện tại

- Bộ test chưa đủ lớn.
- Generation tự nhiên chưa hoàn chỉnh.
- Query dạng “tốt nhất”, “đáng mua” còn khó.
- Crawler phụ thuộc layout HTML của website.

Hướng phát triển

- Mở rộng benchmark lên 100–500 query.
- Hoàn thiện controlled/extractive generation từ context truy hồi.
- Thêm query rewriting hoặc HyDE nếu phù hợp yêu cầu môn học.
- Xây dựng UI demo bằng Streamlit/Gradio.

Cảm ơn cô và các bạn đã lắng nghe!